玉笛百科 JADE FLUTE

HORIZONTAL · VERTICAL ANALYSIS

Decisions API：软件要的是判断，混元还停在写字

横纵分析法深度研究报告

所属领域　AI 应用软件 / 决策模型 / 模型网关

研究对象类型　概念（协议与产品族）兼内部接入层

研究时间　2026年10月14日

研究方法　纵向历史溯源 + 横向竞品对比 + 交汇洞察

研究员　玉笛百科

ENCYCLOPEDIA REPORT

目录

核心结论速览 4
一、纵向分析：从诞生到当下 5
1.1 起源：判断一直在，接口一直错位（2022–2025） 5
1.2 品类被命名：Jev 把 System One 做成函数（2026 年 9 月） 5
1.3 实验室把品类收进自己的栈（2026 年 9 月 22 日–10 月 6 日） 6
1.4 四周竞赛：开源、云厂商、中国云（2026 年 10 月） 7
1.5 混元停在会写 JSON 的快模型（到 2026 年 10 月 14 日） 8
1.6 tt-switch：切的是谁来写字，不是谁来判断 8
二、横向分析：竞争图谱 9
2.1 竞品地图 10
2.2 Decisions API 当前画像 10
2.3 vs Jev：谁先定义协议，谁先长进套件 10
2.4 vs 阿里云决策模型：中国云已经开门 11
2.5 vs 微软 Decision-1：采购路径，不是协议创新 11
2.6 vs 混元栈：槽位在 CMR，模型在别处 12
2.7 vs tt-switch：插头和插座 12
2.8 这种 API 究竟怎么被调用 12
2.9 维度对照 14
2.10 生态位与格局 16
三、横纵交汇洞察 16

3.1 历史如何塑造了当下位置 16

3.2 优势与劣势的历史根源 16

3.3 未来三个剧本 17

四、信息来源 19

五、方法论说明 20

核心结论速览

一句话定义：Decisions API 是一条「不写字、只做有界判断」的专用接口：应用提交一段状态加一组类型化问题，模型返回概率、选项或量表，程序拿回来就能进 `if`。OpenAI 在 2026 年 10 月 6 日把它做成 `POST /v1/decisions`；混元（hy）截至 10 月 14 日公开文档里没有对等端点。司内口语里的 tt-switch，公网证据指向 Claude Code / Codex 一类工具的供应商切换器（CC Switch / TT switch），它切的是聊天协议，接不住一条还不存在的混元 Decisions。

关键判断：

1. 论坛问「hy 什么时候可以出 Decisions API」，问的是混元有没有一条和 OpenAI / Jev 同构的决策通道。公开事实停在这里：TokenHub 2026 年 10 月 13 日的 API 说明只列 Chat Completions、Responses、Anthropic Messages 和 `GET /v1/models`，模型表是 `hy3`、`hy4-preview`、DeepSeek、GLM、Kimi。分类决策在腾讯云上已经有一个槽位，但不在混元身上：模型路由 CMR 同一天更新的调度文档，把「分类决策模型（如 Jev 模型）」写成可选模态，意图路由可以「开启分类决策模型」。槽有了，混元自研决策模型还没有。
2. 这种 API 的主场是工作流和 Agent 套件外侧的闸门，不是 Cursor 对话里再冒出一个 MCP 工具。OpenAI 官方把密钥留在服务端，语音场景走 Live API 的 client-delegation：模型继续说话，应用在旁边调 Decisions、执行动作、把结果塞回去。Jev 社区把同一层做成 Claude Code 的 `PreToolUse` hook 和 Cursor 的 `beforeShellExecution`，主模型一 token 都不用花。MCP（`jev_decide`）可以嵌进对话，那是给 Agent「想起来再问」用的慢路径。Cursor 没有把 OpenAI `/v1/decisions` 做成内置工具，公网也查不到。
3. 「看 OpenAI 和其他厂商的接入速度，应该很容易吧？」协议层确实快。阿里云百炼已经提供 `POST /compatible-mode/v1/systemone`，模型 `decision-model-preview`，官方示例返回 `latency_ms: 52.9`，文档页更新到 2026 年 10 月 11 日。微软 10 月 9 日发布 Microsoft-Decision-1，价签对齐 Jev 的 0.042 美元/百万输入。Cloudflare Clef 更早，10 月 1 日。真正没出独立端点的是 Anthropic、Gemini、DeepSeek、Kimi 和混元。网关转发 Jev 或 Luna 是几天的活；训一套校准过的混元决策头、再让 tt-switch 多一种协议，是两件难度完全不同的事。后者容易，前者才是论坛在等的东西。

机会与风险：

- 机会：内部工具要「简单快速的意图判断」，今天就能用三条现成路：CMR 意图路由挂 Jev、TokenHub 上 `hy3` 的 `json_schema` 凑合分类、或直连 OpenAI Decisions / 百炼 systemone。tt-switch 一旦多一种 Decisions 协议，Claude Code 热路径上的模型选择和工具闸门可以同时变便宜。
- 风险：把 `hy3` 结构化输出当成 Decisions，延迟和校准都还在生成模型那一档。把 MCP 当成主接入方式，等于让会写字的模型决定要不要做判断，判断层的速度优势会被吃掉。混元若只抄接口、不抄校准，上线日会很快，可用性会很差。

一、纵向分析：从诞生到当下

> **叙事主线**：软件一直需要一种模糊的 `if` 。行业先把判断塞进聊天模型，再发现聊天模型会写字、会幻觉、会按 token 收费。有人做出不会写字的决策模型，实验室和云厂商在四周内把同一套协议铺开。混元还停在「会写 JSON 的快模型」，tt-switch 还停在「切换谁来写字」。

1.1 起源：判断一直在，接口一直错位（2022–2025）

客服工单该去哪个组、这条请求要不要调工具、这段补丁过不过测试，这些判断每天发生成千上万次。2018 年以后，固定标签分类器用 BERT 一类模型就能做，标签集在训练时冻死，场景一变就要重训。

2022 年 8 月 10 日，OpenAI 上线 Moderation API。它是 GPT 系分类器，免费，输出一组有害内容类别的分数。用途很窄：内容审核，不是任意业务 schema。

真正把「判断」送进应用开发者手里的，是 2023 年 6 月 13 日的 Function calling。`gpt-4-0613` 和 `gpt-3.5-turbo-0613` 可以输出 JSON 函数参数。模型仍在写字，只是字被规定成参数。2023 年 11 月的 JSON mode 保证合法 JSON，不保证字段对。2024 年 8 月 6 日 Structured Outputs 把 `strict: true` 写进 API，JSON Schema 被语法约束住。

这一串升级解决了「解析失败」。没有解决「每次判断都要生成」。模型会在心里拟一篇分析，再把分析压成字段。延迟按秒计，输出按 token 加价，说出来的 95% 把握对不上长期正确率。Agent 一流行，这个错位被放大。一次能改仓库、开浏览器、跑测试的任务里，微型判断可能有几十上百次：现在该不该搜、这条结果还要不要、用户是在追问还是开新任务。每一问都请 Claude 或 GPT 想一遍，账单和尾延迟会先把产品杀死。

2025 年 10 月 9 日，arxiv 上出现 When to Reason: Semantic Router for vLLM（2510.08731）。它做的是「这条请求要不要走推理」，在 MMLU-Pro 上宣称准确率加 10.2 个百分点、延迟降 47.1%、token 降 48.5%。2026 年 2 月的技术报告把路由写成 13 类信号加布尔决策引擎。这些工作服务的仍是 chat completions：分类器站在大模型门口，大模型继续写字。缺的是把分类器自己做成一种一等 API。

内部工具链其实早就在用土办法填这个缺口。规则：关键词命中就走某个模型。小模型：用 7B、8B 先做一次分类，再把标签塞进路由表。Prompt：在系统提示词里写「只输出 billing 或 technical」。三条路都能跑，也一直在跑。规则太脆，同义词一变就漏。小模型要为每个标签集准备数据。Prompt 最灵活，也最贵最慢，输出偶发飘出 schema。论坛说「蛮多工具可以通过简单快速的意图判断猛猛提效」，指的是把这三条土办法收成一条稳定 API。土办法的存在，说明需求不是新的；独立端点的出现，说明旧接口已经劝退了足够多的人。

1.2 品类被命名：Jev 把 System One 做成函数（2026 年 9 月）

2026 年 9 月 15 日，TypeSafe AI 把 Jev 放进 early access。创始人 Diogo Almeida 是 InstructGPT / RLHF 论文的共同作者。官宣博客把产品写成 frontier-intelligence function call：非结构化状态进，带类型的概率决策出。官网第一句更硬：We took the opposite research direction。

接口形状后来被所有人抄走。一次请求是 `state` 加一组 `questions`。输出只有三种原语：Choice（从给定选项里选一个）、Score（在有序刻度上打分）、Noul（某事是否成立，返回 0 到 1 的概率）。模型不生成文本。官方定价每百万输入 token 0.042 美元，输出免费；端到端延迟写 70 到 500 毫秒。训练方法自称 Reinforcement Learning for Calibrated Decisions（RLCD）：模型说 90% 把握，在代表性样本上大约应该对九成。文档自己写了限制：校准是在一组预测上度量的，不保证单条正确。「can’t hallucinate」保证的是类型，不是真相。

同一周，开发者开始把它塞进三个位置。模型路由：闲聊走小模型，写代码走贵模型。工具门槛：先问现在需不需要工具，再在锁死的工具名里选。验证与监督：大模型写完补丁，外面站一个不写评语、只打分的裁判。Agent 的骨架从「全程 LLM」变成「规则 + 决策模型 + LLM + 工具」。

Jev 还给 Agent 工具链留了门。jevmodel.org 提供远程 MCP，工具名 `jev_decide` / `jev_noul` / `jev_choice` / `jev_score`，文档写明面向 Claude Code、Cursor、Cline。这条路径后来常被误读成「Decisions 就是 MCP」。它只是 Jev 的一种封装。官方设计仍然是应用自己 `POST /v1/systemone`。

社区把同一层又往下凿了一格。有人在 Claude Code 清上下文：终端输出和工具结果先交给 Jev 打分，只把仍与当前任务相关的片段留给大模型。有人拿 Agent 执行记录问它：目标完成了没有、有没有漏项。有人用它在几十秒里拆几百条广告。这些用法有一个共同点：判断发生在主模型的上下文预算之外。主模型越贵，这一刀越值得。混元论坛里「简单快速的意图判断猛猛提效」，指的就是这一刀，不是再让 `hy3` 多写一段分析。

1.3 实验室把品类收进自己的栈（2026 年 9 月 22 日–10 月 6 日）

2026 年 9 月 22 日，OpenAI changelog 发布 GPT-6 Sol 和 GPT-6 Luna，当时它们是生成模型。Luna 走 Responses API 时，输入 0.10 美元/百万 token，输出 0.50 美元，支持 function calling、structured outputs、streaming、prompt caching。

7 天后的 DevDay（9 月 29 日），Decisions API 以 limited preview 亮相。官方 recap 写它会在 coming days 做更广的 release。

10 月 6 日，公开 beta。社区帖创建于 UTC 20:53。changelog 同日。Python SDK PR #4033 20:50 开、21:09 合，发布进 v3.26.0；Node PR #2886 合进 7.30.0。官方指南把产品写成一句话：

> The Decisions API evaluates text, images, or both and returns typed answers about 10x faster than the Responses API.

端点是 `POST https://api.openai.com/v1/decisions`。模型目前只有 `gpt-6-luna`。请求三块：`model`、`input`（文本或带 inline base64 图的 user 消息）、`questions`。输出三种：`predicate`（条件为真的概率）、`choice`（固定选项）、`score`（有序量表的概率加权平均）。另外还有

`refusal`。定价：Luna 走 Decisions 时只收输入 0.10 美元/百万 token，不收 cache-read、cache-write、output。官方明确对比：需要自定义 JSON 对象或 tool arguments 时，仍用 Responses；需要这三种答案时，才用 Decisions。

OpenAI 没有宣称新架构或 RLCD。它给已经会聊天的 Luna 开了一条更快的决策通道。社区立刻拿它和 Jev 比。有人测图像输入在约 3 Mbps 网上大约 0.8 秒；有人在几百题小样本里看到 Jev 中位约 0.3 秒、Luna 约 1.6 秒。有人发现 predicate 校准较好，choice 会把 70% 的硬币压成 98% heads。这些是社区实验，不是官方 SLA。官方毫秒级延迟、独立 API Reference schema、GA 日期，截至本调研仍暂缺。指南只说 expect to GA in the coming weeks。

语音是 OpenAI 相对 Jev 的差异化。文档 Connect voice to Decisions 规定 client-delegation：GPT-Live 继续说和听，应用在 `session.delegation.created` 之后自己调 Decisions，执行 `back` / `reload` / `noop` 这类动作，再用 `session.commentary.append` 让 Live 开口汇报。复杂请求可以把 `reason` 做成一个 choice，再转 Responses 上的推理模型。Luna 模型卡写明 Live 本身 Not supported。语音会话是 GPT-Live，Decisions 是应用在 delegation 窗口里的侧路调用。

1.4 四周竞赛：开源、云厂商、中国云（2026 年 10 月）

窗口被挤满的速度，比混元论坛里的等待更说明问题。

10 月 1 日，Cloudflare 发布 Clef / Clef-flash，Apache-2.0，挂在 Workers AI，API 按 Jev 的 System One 形状兼容。骨干冻结 Qwen，推理只做 prefill，再对合法 schema 并行打分。厂商 43-eval 表上，Clef 中位 209.3 毫秒，Clef-flash 38.8 毫秒，同表 Jev 524.1 毫秒。changelog 把 Agent guardrails 写成「调工具前几十毫秒」。

10 月 9 日，微软发布 Microsoft-Decision-1。基座是 Qwen3.5-9B 后训练，Foundry 路径 `{foundry}/providers/microsoft/v1/systemone`，定价直接写成 0.042 美元/百万输入、输出免费。稿件举 Xbox Research 超过 1 万条反馈、Copilot 质检、值班检索。附录把 GPT-6 Luna Decisions 列为对比对象。

10 月 11 日前后，vLLM Semantic Router 开源 Decision 3.0。Hugging Face 上的 d3 能看多图和视频。模型卡 10 月 13 日在单卡 AMD MI325X 上测文本一问 p50 54.4 毫秒。智东西 10 月 12 日那篇「Jev 对手来了」，说的就是它。本百科已有单独的 Jev 横纵报告，这里只把它当作协议扩散的证据。

同一窗口里，阿里云百炼上线了决策模型 API。帮助中心页写：`POST /compatible-mode/v1/systemone`，模型 `decision-model-preview`，一次前向返回分类、评分、是非判断及概率，不生成文本。问题类型是 choice / noul / score，和 Jev 同构。Python 示例直接 `pip install typesafe-sdk`。官方返回示例带 `latency_ms: 52.9`。模型信息页更新时间 2026 年 10 月 11 日，北京和新加坡两地标「限时免费」，限流 1200 RPM、200 万 TPM，上下文 65536，最大输出长度 0。中国云厂商里，公开把 System One 做成一等 API 的，目前能核到的是阿里。

Anthropic 没有独立 Decisions。官方 ticket-routing 指南仍用 Messages + 小模型 + 强制 tool。Gemini 走 Interactions API 加 JSON Schema / `text/x.enum`。DeepSeek 补的是 Anthropic 兼容 `https://api.deepseek.com/anthropic`。月之暗面 Kimi 公开兼容列表有 chat completions、responses、messages，没有 `/v1/decisions`。百川开放平台未见 systemone。这些实验室选择继续用生成模型做判断，只是把 JSON 约束得更死。

1.5 混元停在会写 JSON 的快模型（到 2026 年 10 月 14 日）

hy 是混元在内部和 TokenHub 上的简称。TokenHub 模型 ID 已经从 `hunyuan-turbos-*`、`hunyuan-t1-*`、`hunyuan-functioncall` 迁到 `hy3` / `hy3-preview` / `hy4-preview`。旧版 ChatCompletions 的 `Tools` 曾绑定在 turbos、t1、functioncall 上。新文档把 Function Calling、`response_format.json_schema`、深度思考、Cache 写进 `hy3` 和 `hy4-preview`。

这些能力都还在写字。结构化输出保证字段形状，function call 保证工具参数 JSON，快思考（混元 Turbo S 那条「秒回」叙事，以及 TokenHub 的 `reasoning_effort`）缩短的是第一个生成 token。没有一条接口声明：我拒绝生成文本，只返回 predicate / choice / score。

TokenHub API 使用说明最近更新 2026-10-13 15:50:30。域名 `https://tokenhub.tencentmaas.com`，鉴权 Bearer，`GET /v1/models` 示例里是 `hy3` 和 `deepseek-v4-pro`。兼容协议是 OpenAI Chat Completions、OpenAI Responses、Anthropic Messages。`/v1/decisions` 和 `/v1/systemone` 在这一页上不存在。

混元原生 API 概览（1729/101848）列的是 ChatCompletions、ImageQuestion、GetEmbedding、生图、翻译。产品动态页检索「Decisions / System One / 决策模型」无官方宣布。公开 roadmap 暂缺。司内论坛那句「hy 什么时候可以出 Decisions API」，公网零命中，按司内讨论处理，不编造帖文和时间表。

腾讯云并不是没看见这个品类。CMR（Cloud Model Routing，产品 1829）2026 年 10 月 13 日 19:34:30 更新的《配置模型调度管理》写得很直白。步骤 1 选模态：文本生成、视频生成、向量嵌入、重排序、分类决策模型（如 Jev 模型）。步骤 3 意图路由有开关「开启分类决策模型」：开启后用本实例关联的分类决策模型做意图路由。客户端仍可走 OpenAI / Anthropic 兼容，Claude Code 文档把 `ANTHROPIC_MODEL=ModelRouter/auto` 指到 CMR。这是腾讯公有云上最接近 Decisions 的产品位。挂进去的决策模型，文档举例是 Jev，不是混元。

旁边还有两层更老的「意图」：云原生智能网关的意图识别路由，先调一个 NLU 再按置信度阈值（文档推荐 0.70）打到业务模型；智能体开发平台的「大模型意图识别节点」，画布里最多 20 个意图。前者多一次生成调用，后者是工作流节点。它们能分流，给不出 Luna / Jev 那种校准概率原语。

1.6 tt-switch：切的是谁来写字，不是谁来判断

公网没有腾讯官方把「tt-switch」登记成混元服务。能钉死的是同一形态的切换器。

CC Switch 是开源桌面应用，仓库 `farion1231/cc-switch`，MIT，Tauri 2。它给 Claude Code、Claude Desktop、Codex、Gemini CLI、Grok Build、OpenCode、OpenClaw、Hermes 做供应商一键切换，可选本机 sidecar（默认 `127.0.0.1:15721`）做协议转换。腾讯云 TokenHub 官方文档（1823/136605、1823/136601）教如何在 CC Switch 里接 Token Plan 企业版和个人版：Anthropic 走 `.../plan/anthropic`，OpenAI Completions 走 `.../plan/v3`。v3.19.1 给 Codex 加了「Tencent Hunyuan」预设，直连 `https://tokenhub.tencentmaas.com/v1`，`wire_api=responses`，模型 `hy3` / `hy3-preview`。GitHub issue #5592 要求加 Cursor 支持，被标重复后关闭，官方仍不支持 Cursor。

一份公开笔记把这套东西直接写成「TT switch」，标题是 OpenCode Zen 接入 Claude Code / TT switch，行为与 CC Switch 一致：本机代理、`PROXY_MANAGED`、模型映射，并写明其他 provider 包含「腾讯内网」。验证命令是 `curl http://127.0.0.1:<TT_SWITCH_PORT>/v1/messages?beta=true`。

据此可以下一个有证据的判断：腾讯员工口语里的 tt-switch / TT switch，很大概率就是 CC Switch 或内部 fork，用来把 Claude Code 在官方 Claude、腾讯内网、TokenHub 混元之间切换。它转换的是 Messages / Chat Completions / Responses。它不实现混元 Function Call，更没有 Decisions 协议。论坛说「让 tt-switch 接入下」，工程含义是：混元一旦有 `/v1/decisions` 或 `/v1/systemone`，在切换器里加一种协议、一个模型 ID，让内部工具沿用同一套 Key 和本地端口。司内若另有完全同名的网关服务，维护团队和内网 endpoint 公开材料暂缺，不编造。

若只看「接入速度」，OpenAI 自己的动作其实也分两截。Luna 作为生成模型是 9 月 22 日发布的；Decisions 专用通道晚了 14 天。SDK 在公开 beta 同一小时合进主干，说明接口形状事先锁死了，不是上线当天现写。阿里在 10 月 11 日的模型信息页上已经把最大输出长度写成 0，这是产品经理愿意承认「这个模型不会说话」的标志。混元到 10 月 14 日仍把 hy3 的卖点写在深度思考和 Function Calling 上。思考越深，离 Decisions 越远。决策模型要的是浅、快、校准、类型锁死。

纵向走到今天，故事卡在两截。外面：决策已经从「prompt 里求 JSON」变成独立端点，阿里比混元先把门开了。里面：tt-switch 很会给写字的模型换插头，判断这条线还插在生成模型的插座上。论坛把两截捏成一句话来问，听起来像一个功能请求，拆开是两个团队的活：模型侧要不要训头，网关侧要不要加协议。

二、横向分析：竞争图谱

> 切面时间：2026 年 10 月 14 日。触发材料是司内论坛「hy 什么时候可以出 Decisions API，让 tt-switch 接入」。

2.1 竞品地图

这是场景 C。用户真正拿来对比的，不是「另一个聊天模型」，而是「谁能提供可嵌入控制流的判断」。选取六个代表：

1. OpenAI Decisions API：实验室给 Luna 开的专用通道，名字就是论坛在喊的那个词。
2. Jev / System One：品类定义者，MCP 和 hook 文档最全。
3. 阿里云 `decision-model-preview`：中国云上已经能买到的 System One。
4. Microsoft-Decision-1：企业采购路径上的官方决策模型。
5. 混元 + TokenHub + CMR：腾讯侧现状，槽位和模型错位。
6. tt-switch / CC Switch：本地接入层，决定内部工具明天能不能用上第 1 到第 5 项。

Cloudflare Clef 和 vLLM d3 在 Jev 专文里展开过，这里只在对照表里保留，避免把同一场四周竞赛写两遍。

2.2 Decisions API 当前画像

定位：应用服务器上的判断函数。官方 playground 让你先试 questions 和 input，再写代码。SDK 入口是 `client.decisions.create`。

一次典型调用像这样：工单文本进 `input`，`questions` 里并行放「是否报损」（predicate）、「派哪个组」（choice）、「紧急度」（score）。回来的 `answers` 按 `name` 对齐。choice 和 score 带 `probabilities` 与 `confidence`。应用自己设阈值：高置信度自动执行，低的转人工或升级到推理模型。

它明确不做什么。不写 tool arguments，不吐自定义 JSON 对象，不流式生成，beta 期间没有 prompt caching。图像必须 inline base64，不接受 URL 和 `file_id`。依赖前一答案的决策要拆成多次请求。

目标用户是要把判断写进代码的人：网关、客服路由、Agent 套件、语音动作选择。商业模式沿用 OpenAI 账号和 ZDR / HIPAA。口碑从社区帖就能读到两极：有人立刻拿去分类反馈；有人警告不要用 choice 做校准敏感的概率，predicate 更老实。

2.3 vs Jev：谁先定义协议，谁先长进套件

Jev 比 OpenAI Decisions 早 21 天进入 early access。开发者先记住的是 `state + questions` 和 noul/choice/score，不是 `input + predicate`。OpenAI 换了字段名，语义几乎一一对应：predicate ≈ noul。定价 Luna 约是 Jev 的 2.38 倍。Jev 官方延迟 70–500 毫秒，OpenAI 只给「约 10 倍于 Responses」。Jev 不能看图；Luna Decisions 能看 inline 图。Jev 权重封闭；OpenAI 走实验室账号。

调用形态上，Jev 更早长进 Agent 套件。官方 MCP 面向 Cursor；社区 `jev-use` 给 Claude Code 提供 `PreToolUse` 闸门：Bash / Write / Edit 在执行前先问 Jev 是否可逆，主模型零 token。jevwiki 把同一套 hook 映射到 Codex、Cursor `beforeShellExecution`、opencode。OpenAI 的官方套件路径是语音 Live + 服务端 Decisions，不是 Cursor 插件。

用户选 Jev，是因为文档、校准叙事、以及已经写好的 hook。用户选 OpenAI Decisions，是因为账号已经在、能看图、以后和 Responses / Agents 在同一栋楼。对腾讯内部，「合适的使用 API」这两家都能算合适，前提是数据能出境。出不了境，Jev 和 Luna 都过不了第一关。中文工单、中文代码评论、中文对话质检，Jev 文档自己写了 CJK 弱于英文、要自测。这是混元若出决策头，唯一不需要靠速度就能站住的理由：数据在境内，语言是主场。速度可以买开源 d3，语言和驻留买不来。

OpenAI 把 Decisions 做成 Luna 的专用通道，还有一层组织含义。Almeida 在 OpenAI 参与了让模型听话，离开后去做不说话的模型。老东家没有否认品类，而是把品类收进 GPT-6 的产品矩阵。混元没有这个传记包袱，也没有 Luna 那种现成小模型通道被写进模型卡。它要抄，抄的是接口和训练目标，抄不了「我们本来就有一条更快的 Luna」。因此「应该很容易」如果指 SDK 加一个 `client.decisions.create`，是的；如果指 hy3 明天改个路由就能当闸门，公开材料不支持这个乐观。

2.4 vs 阿里云决策模型：中国云已经开门

百炼的 `decision-model-preview` 走 TypeSafe System One，不是 OpenAI `/v1/decisions`。这对国内团队更省事：typesafe-sdk 换 `base_url` 就能打到北京或新加坡。工单分流示例一次请求问部门、是否升级、严重度，官方返回里 `latency_ms` 52.9、`confidence` 0.88 / 0.91。价格页写限时免费，不能当成长期单价。Function Calling、结构化输出、联网、微调，能力表上全是「不支持」——它承认自己不是生成模型。

和混元比，阿里把「决策」做成了独立模型 ID 和独立路径。混元把「判断」继续塞在 `hy3` 的 `json_schema` 里。论坛里那句「司内好像没有合适的使用 api」，对照百炼这一页，落差非常具体：阿里的开发者今天能 `POST .../systemone`；腾讯的开发者今天能 `POST .../chat/completions` 然后自己解析 JSON。解析这一步看起来小，落到 Agent 热路径上就是：多一次 schema 失败重试、多一段被模型写出来的解释、多一截无法设阈值的假置信度。百炼把最大输出长度写成 0，就是为了从根上取消这三笔开销。

阿里也没有宣布这套东西进了 CC Switch。Token Plan 文档有「接入决策模型」的评论审核教程，走的是 AI 工具扩展机制和 `/compatible-mode/v1/systemone`，仍然是应用侧调用。中国云赛道上，混元要追的第一名是这个端点，不是再发一个更快的 hy4。

2.5 vs 微软 Decision-1：采购路径，不是协议创新

Microsoft-Decision-1 抄的是 System One，价签对齐 Jev，基座是 9B 的 Qwen 后训练。它卖的是 Foundry 合规和「我们已经在 Xbox / Copilot 里用了」。对已经买 Azure 的企业，这降低安全审查摩擦。对腾讯，它提供一个参照：用现成的 Qwen 后训练，十天内可以做出可售的决策模型。混元自己有稠密和 MoE 权重，缺的不是基座，是把输出头从自回归生成改成并行打分，再配一套校准训练。微软稿件里的 35 倍、100 倍、200 倍都是对自家生成模型的相对值，不能直接拿来预测混元上线日。

后训练这条路值得单独说一句。Clef、Decision-1、d3 的骨干都是 Qwen 家族，冻结或轻量后训练，推理时对合法选项并行打分。混元若坚持「必须用自研基座才叫 hy Decisions」，日历会比「先用混元或通义做一版后训练头、挂上 CMR」更长。论坛要的是能用的 api，商标写在哪家权重上是第二问。TokenHub 已经在卖 DeepSeek、GLM、Kimi，决策头哪怕第一版不是混元自家名字，只要路径在、数据不出境，tt-switch 就可以接。坚持名字正确、接口缺席，是把品牌顺序放在了提效前面。

2.6 vs 混元栈：槽位在 CMR，模型在别处

把腾讯侧拆成三层，错位才会清楚。

模型层（hy3 / hy4-preview）：会聊天、会 tools、会 json_schema、会调 `reasoning_effort`。用它做意图判断，得到的是生成出来的标签。延迟跟生成走，校准没有官方成绩单。这是「可以凑合」，不是 Decisions。

网关层（TokenHub）：一 Key 调混元和第三方，协议停在写字。Cursor、CodeBuddy、Claude Code 的官方接入指南都指向这里。它今天切的是 `model` 字符串，不是 `questions` 数组。

路由层（CMR）：已经认识「分类决策模型」这个模态，举例 Jev，意图路由可开关。Claude Code 用 `ModelRouter/auto` 时，分流发生在网关，应用无感。这是腾讯云最接近「让 tt-switch 接入」的现成答案：tt-switch 把上游指到 CMR，CMR 挂 Jev 或未来的混元决策模型。混元自己不出模型，这个开关挂的就永远是别人的决策头。

智能体画布上的意图识别节点适合客服机器人，不适合 IDE 热路径。LLM-WAF 做的是放行/拦截/代答，是安全策略，不是给 Agent 当 Decisions 用的概率 API。

2.7 vs tt-switch：插头和插座

tt-switch 解决的问题是：Claude Code 今天打官方 Anthropic，明天打 TokenHub `hy3`，后天打腾讯内网，不要手改一堆环境变量。它是插头。Decisions 是一种新插座。

插头很好做。CC Switch 已经在 Completions、Responses、Anthropic Messages、Gemini Native 之间转换。再加 `/v1/decisions` 或 `/v1/systemone`，对切换器作者是增量协议。TokenHub 官方既然已经为 CC Switch 写了两页文档，混元 Decisions 一旦存在，最省事的分发就是：TokenHub 暴露端点，CC Switch / tt-switch 加预设，内部论坛那句话就算落地。

插头解决不了插座空着。Cursor 还不受 CC Switch 支持，内部若主力是 Cursor，tt-switch 接入也喂不到对话里。那条路径要手改 Cursor 的 OpenAI 兼容 Base URL，或自建 MCP 把 Decisions 包成 tool。后者能用，会把判断重新塞回「模型决定调不调工具」的慢循环。

2.8 这种 API 究竟怎么被调用

用户问：是接入工作流，还是像 Cursor 这样的 IDE 会通过 MCP 嵌在对话里触发？答案是四条路同时存在，快慢差一个数量级。主路不是 MCP。

第一条，应用侧路。这是 OpenAI 官方设计。 工单系统、网关、语音后端在服务端 `POST /v1/decisions`，密钥不进浏览器、不进 IDE。返回值进业务 `if`：派哪个队列、是否退款、要不要升级模型。Vercel AI Gateway 已经暴露兼容的 `/v1/decisions`，模型 ID 写成 `openai/gpt-6-luna-decisions`，AI SDK 有 `experimental_decide`。LangChain 一类编排器把决策节点画在图里，和「工作流」是同一件事。

第二条，Agent 套件钩子，对话外拦截。 Claude Code `PreToolUse`、Cursor `beforeShellExecution`、Codex 同名 hook，在工具真正执行前问决策模型：这次 `rm` 可不可逆、这次 `git push` 要不要人看。 `jev-use hook gate` 写明：主模型零 token，Jev 不可达则 fail open。这是 IDE 里最值钱的用法，而且用户看不见一次「工具调用」气泡。判断发生在套件层，不发生在对话层。

第三条，MCP 工具，对话内触发。 Cursor 读 `.cursor/mcp.json`，Jev 的 MCP 提供 `jev_classify` / `jev_score` / `jev_check` / `jev_gate` / `jev_decide`。Agent 在任务中途「想起来」可以问一句。代价是：主模型必须先决定调用这个 tool，判断的延迟叠在一轮 function calling 上。MCP 文档自己也写：Jev 看不见对话和本地文件，state 要调用方喂全。把 Decisions 理解成「Cursor 里自动冒出来的意图判断」，和现有实现不符。OpenAI 没有官方 Decisions MCP。

第四条，网关意图路由，调用方无感。 CMR `ModelRouter/auto`、云原生网关的 NLU 分流、Semantic Router 论文里的「何时推理」，请求进门时已经被打到便宜或昂贵的后端。应用仍发聊天协议。这是 tt-switch 最容易接的形态：切换器只换 Base URL，决策发生在上游。

语音是第一条的变体。GPT-Live 不停，Decisions 在旁边选动作。幻灯片「下一页」走 choice，`reason` 再转推理模型。Cursor 聊天没有对等的 delegation 窗口。

把四条路放进一条内部编码任务里，快慢差会变得非常具体。假设用户在 Claude Code 里说「把这次的错误日志归到哪个组和要不要热修」。主模型若自己用 tools 分类，至少要生成一串 JSON，再被解析，再决定下一步，前后一两秒很常见。若 PreToolUse 或服务端先打 Decisions：choice 选出 `platform` / `backend` / `client`，predicate 给出「是否热修」的概率，50 到 200 毫秒后规则引擎已经分支。主模型接到的是已经切好的上下文，只负责改代码。MCP 路径夹在中间：主模型先「想到」要调 `jev_decide`，写一次 tool call，等 MCP 返回，再继续。能用，比全程生成稳，比 hook 慢，而且模型可能根本想不起来调。

Cursor 对话里的情形更苛刻。Agent 已经带着一长串 MCP。每多一个 tool，选错工具的概率上升。把 Decisions 做成其中之一，等于用贵模型去决定要不要用便宜模型。官方设计把这个决定从模型手里拿走：应用或套件在模型开口之前就问完。这是「嵌在对话中被触发」听起来方便、做起来亏的原因。

所以：工作流 / 网关 / 套件 hook 是 Decisions 的主场；MCP 是可选的慢封装；把希望寄托在「对话模型自己触发」上，会把这个品类做回去。内部若只让 tt-switch 把混元 Decisions 暴露成又一个 chat model，开发者仍会用 prompt 求 JSON，论坛想要的提效不会出现。

2.9 维度对照

维度	OpenAI Decisions	Jev	阿里 decision-model-preview	微软 Decision-1	混元现状	tt-switch
公开时间	2026-10-06 beta	2026-09-15	文档见 2026-10-11	2026-10-09	无独立端点	社区工具；TokenHub 文档已教接入
路径	`POST /v1/decisions`	`/v1/systemone` 或 `/v1/decide`	`/compatible-mode/v1/systemone`	Foundry `/v1/systemone`	Chat Completions / Responses / Messages	本地转换上述写字协议
模型	`gpt-6-luna`	`jev-latest` 等	`decision-model-preview`	Microsoft-Decision-1	`hy3` / `hy4-preview`	不生产模型
原语	predicate / choice / score	noul / choice / score	同 Jev	同 Jev	JSON / tool calls	无
输入价	0.10 美元/百万 token	0.042 美元/百万	限时免费（长期价暂缺）	0.042 美元/百万	按生成模型计	本机免费
官方延迟	约 10× Responses；无 ms	70–500 ms	示例 52.9 ms	相对 GPT-6 Sol ~35×	生成时延	本机代理开销
图像	inline 图	无	文本	文本为主	视具体 hy 模型	透传
IDE 主路径	服务端；语音 delegation	MCP + PreToolUse hook	应用扩展 / API	Foundry	无	切 Claude Code / Codex 供应商
国内合规	美欧 residency	美西节点	北京 / 新加坡	Azure	国内 TokenHub	可指内网

2.10 生态位与格局

品类已经从「Jev 一家定义」变成「协议竞赛」。接口几乎同构，差异在延迟、校准、能否看图、数据驻留。格局是百花齐放，没有两强争霸。混元缺席的是模型，不是认知：CMR 文档把 Jev 写进模态列表，说明腾讯云产品侧已经把分类决策当成一等公民。tt-switch 站在客户端，生态位是「让内部 IDE 换上游」，它填补的空白是配置，不是智能。

用户真实选择很分层。能出海的团队，OpenAI Decisions 和 Jev 今天就能嵌进工作流。必须留在国内的团队，阿里 systemone 是现成插座，腾讯 CMR+Jev 是网关插座，混元自己是空的。写 Claude Code 的人会催 tt-switch；写 Cursor 的人催了也暂时接不上，要另开 MCP 或手改 Base URL。CodeBuddy 走 TokenHub 官方接入，和 Cursor 一样吃的是写字协议，短时间内不会因为 tt-switch 多一个预设就自动出现意图闸门。谁在哪一种 IDE 里编码，决定了「接入」三个字落在 hook、MCP 还是网关。论坛把它们写成同一个需求，落地时会拆成三条补丁。

三、横纵交汇洞察

3.1 历史如何塑造了当下位置

Function calling 把判断塞进会写字的模型，锁死了 2023 到 2025 年所有「智能路由」的样子：先生成，再解析，再重试。Jev 把生成拿掉，协议才能薄到可以当函数。OpenAI 用 Luna 另开端点，承认品类，但继承了「大模型做判断」的实验室路径，所以贵一点、官方延迟叙事也只敢写相对 Responses 的 10 倍。阿里直接兼容 System One，用 typesafe-sdk，等于承认协议标准已经不在自己手里。

混元的历史选择是另一条：把 functioncall、turbos、t1 收进 `hy3`，把思考开关收成 `reasoning_effort`，把网关做成 TokenHub 三协议。这些选择让混元在 Coding Agent 里很好用，也让它错过「输出长度为零」这一跳。CMR 愿意挂 Jev，说明产品经理看见了缺口；模型侧还在优化写代码。缺口于是表现为论坛提问。

tt-switch 的历史更短，路径更窄。它跟着 Claude Code 的 Anthropic 协议长出来，官方被 TokenHub 收编进接入文档。它从来只转换「谁来生成下一串 token」。要它接入 Decisions，必须先有一种不是 chat 的上游。历史把它放在插头的位置上，插座却还没打孔。

3.2 优势与劣势的历史根源

强项：判断从 prompt 里搬进了类型。 根源是 Almeida 拒绝再让模型对人说话。没有 9 月 15 日那一刀，10 月不会有五家抄同一张表。

强项：调用可以完全离开对话。 根源是 OpenAI 把密钥留服务端、Jev 把 gate 做成 hook。套件作者发现，最值钱的判断发生在工具执行前，不发生在聊天气泡里。

强项：腾讯云网关已经认识这个模态。 根源是 CMR 要把意图路由做成可卖的企业功能，Jev 是最快能填进去的外脑。

包袱：混元的产品惯性是生成。 `hy3` 越会写代码、越会 tools，内部就越容易觉得「json_schema 已经够用」。够用生成标签，不够用当 50 毫秒的闸门。

包袱：tt-switch 覆盖不到 Cursor。 根源是 CC Switch 的工具名单里从来没有 Cursor。论坛如果混用「所有内部 IDE」，接入日会对不上。Cursor 吃 OpenAI 兼容协议，TokenHub 已经有 `/v1` 和 `/v1/chat/completions`；缺的仍是 Decisions 那条路径。即便混元明天开孔，Cursor 也要在模型设置里加一个自定义端点，或等某个内部 MCP 把 `hy-decisions` 包成 tool。切换器解决不了 IDE 厂商自己的协议清单。

包袱：choice 的校准陷阱。 OpenAI 社区用硬币实验打过脸。混元若上线日只抄 choice、不提供可靠的 predicate/noul，工具链会把错误的高置信度写进自动执行。predicate 问的是「这件事是不是真的」，概率轴是连续的；choice 问的是「在这几个名字里选一个」，模型容易把质量压到看起来最像的那一项上。工单分流用 choice 没问题，安全闸门应当用 predicate。接口抄齐三种原语，不等于三种都能拿来设阈值。

当初把 Function Calling 做进混元，是正确的 2024 年决策。2026 年 10 月，它变成一种错觉：有 tools 就等于有 Decisions。tools 是模型请求执行并填写参数；Decisions 是应用先判定再执行，模型不写参数。两件事在官方文档里被 OpenAI 写成并列的「不要混用」。

3.3 未来三个剧本

- 最可能：混元短期内不出对等的自研决策模型。内部要提效，走 CMR 挂 Jev 或直连百炼 / OpenAI Decisions；TokenHub 继续只做写字协议。tt-switch 加一个「决策上游」预设，指到 CMR 或外部 systemone，而不是等 `hy-decisions` 这个模型 ID。论坛提问会再出现几次，答案是「先用网关槽」。时间尺度：数周到一个季度能看到网关侧的说明，混元模型卡上出现独立决策 ID 的公开计划仍暂缺。 `hy3` json_schema 会继续被当成权宜之计，延迟和校准都不会让人满意。
- 最危险：混元用 `hy4-preview` 套一层 schema，对外叫 Decisions，tt-switch 也接了。调用方以为拿到了 50 毫秒的闸门，实际仍在付生成时延，choice 置信度不可设阈值。IDE 热路径上的误拦截和漏拦截一起出现：该拦的 `rm` 没拦，不该拦的 `ls` 被 hook 挡住。品类在司内被写坏，再要推真正的并行打分模型，会先撞上一次「我们试过，不好用」。
- 最乐观：混元用现有权重做后训练，CMR 文档里的「分类决策模型」换上自研 ID，TokenHub 增加 `/v1/decisions` 或 `/v1/systemone`，tt-switch 加协议，Claude Code 的 PreToolUse 和内部工作流共用一个国内端点。阿里已经证明接口可以在 OpenAI 公测后数日内出现；微软证明 9B 后训练可以上架。混元有数据驻留优势，中文工单和中文代码 diff 是 Jev 文档自己划的弱区。这条剧本需要的不是再发一篇「混元更会思考」，而是年报式的产品页：最大输出长度 0、原语三选一、给出可复核的延迟和 ECE。

我的判断靠近「最可能」偏积极的一侧。积极在网关：CMR 已经把开关做出来，tt-switch 接 CMR 比等混元训头更快。保守在模型：公开材料里看不到混元决策头的训练叙事，不能把阿里的速度外推成混元的承诺。10 月 13 日 TokenHub 和 CMR 两页文档同一天更新，一边仍无 Decisions 路径，一边已能挂 Jev。产品侧的优先级，写在这两页的差异里。

对「应该很容易吧」这个问题，可以分三层答。协议翻译很容易，CC Switch 一直在做这种活。网关挂 Jev 也很容易，文档开关已经在。自研一个让人敢把阈值写进生产的混元 Decisions，取决于校准数据、中文评测和是否肯把输出长度做成零。后一件事，OpenAI 用现成 Luna 开通道都还只敢标 beta；混元没有 Luna 那种现成的「决策专用推理路径」被写进模型卡。容易的是接入，不容易的是判断本身变得可依赖。

若一定要给内部排期一个可操作的顺序，我愿意把「容易」写成三张工单，而不是一个上线日。工单 A：CMR 实例关联 Jev 或百炼 systemone，意图路由打开「分类决策模型」，tt-switch 增加一个 CMR 上游。这一张不碰混元权重，公开文档已经够写 runbook。工单 B：TokenHub 增加 `/v1/decisions` 或 `/v1/systemone` 的协议兼容，先把外部决策模型纳管进来，模型 ID 可以暂时不是 `hy-*`。工单 C：混元训决策头，最大输出长度写成 0，给出中文工单和代码 diff 上的延迟与校准。论坛问的是 C，开发者下周能用的是 A。把 C 的等待投射到 A 上，才会觉得「怎么还不让 tt-switch 接入」。tt-switch 能接的，今天就是 A 和 B。

调用方式上，内部该怎么接，也可以说具体。工作流、客服、内容审核：服务端直打 Decisions / systemone，结果进规则引擎，不要进聊天记录。Claude Code / Codex：hook 闸门走决策模型，主模型继续写代码；tt-switch 只负责把 hook 的上游指到国内端点。Cursor：今天用 Jev MCP 或自建 MCP 包一层；不要等 tt-switch。CMR：把 ModelRouter 打开，分类决策挂 Jev 或未来的 hy 决策模型，应用继续发 Messages。四条路里，MCP 嵌在对话中是补充，不是主路径。论坛想要的「简单快速的意图判断」，发生在对话开始之前，以及工具执行之前。

还有一种会被低估的接法：批量。客服夜里积压一万条评论，决策模型按条打 choice，置信度低于阈值的才进人工队列。Jev 和百炼的文档都把这一类写成主场景。它和 IDE 无关，和 tt-switch 也无关，却是「合适的使用 api」四个字里人数最多的那群人。如果混元只为 Coding Agent 做 Decisions，会把这条现金流和这条稳定性验证一起丢掉。校准必须在批量数据上度量，IDE 热路径的样本太少，不够把 ECE 跑出来。先服务工单，再服务 hook，顺序反过来，阈值会拍脑袋。

把时间再拉长一格。2022 年的 Moderation 是固定类别的审核函数。2023 年的 Function calling 是模型请求工具。2024 年的 Structured Outputs 是生成被 schema 锁住。2026 年 9 月的 Jev 是生成被取消。2026 年 10 月的 Decisions API 是实验室承认：软件要的判断，不应该再从一段散文里挖。混元还站在 2024 年那一格，只是模型更强、网关更全。tt-switch 站在客户端，等的是 2026 年那一格的插座。插座一旦打孔，接入不会难。打孔之前，催 tt-switch 解决不了论坛里的那句话。

我愿意把这句话翻译成内部能分发的口径。Decisions API 是给软件用的判断函数，不是给聊天用的新模型。tt-switch 是给 IDE 换上游的插头，公网对应 CC Switch 一类切换器，不是混元本体。调用主场在工作流、网关和工具钩子，MCP 只是对话里的慢封装。混元公开侧还没有这个函数；腾讯云 CMR 已经为 Jev 留了槽。想提效的人，先把槽用上。想等 hy 两个字母印在模型 ID 上的人，公开材料给不出日期。容易的是插头，缺的是插座。口径只此一段，后面都是证据。若有人追问「那我们自己用 hy3 先顶上行不行」，行，当作过渡，不要写进闸门的自动执行。json_schema 可以分流，不宜拿生成出来的「把握」去拦 `rm`。过渡期的正确姿势是：分类可以自动，破坏性动作仍然问人。等真正的决策端点给出可复核的概率，再把阈值往下拧。过渡期多花一点人工确认，比把未校准的 JSON 写进生产更便宜。闸门

一旦误伤开发者日常命令，决策 API 会在内部先失去信任，再失去预算。信任要用批量评测换，不能用上线日换。评测集先放中文工单和代码 diff，再放英文公开题，顺序反了会重复 Jev 在 CJK 上已经写下的弱点。

四、信息来源

1. OpenAI Decisions 指南 — 访问日期 2026-10-14 — 端点、三类型、定价 0.10 美元/百万输入、约 10× Responses、SDK 版本、GA 预期
2. Connect voice to Decisions — 访问日期 2026-10-14 — client-delegation、choice 选动作、reason 转 Responses
3. OpenAI 开发者社区：Decisions API Public Beta — 访问日期 2026-10-14 — 2026-10-06 20:53 UTC、社区延迟与校准讨论
4. openai-python PR #4033 — 访问日期 2026-10-14 — 2026-10-06 合并，`decisions.create`
5. TypeSafe：Introducing System One Models & Jev — 访问日期 2026-10-14 — 2026-09-15、RLCD、0.042 美元/百万 token
6. 阿里云：决策模型 System One API — 访问日期 2026-10-14 — `decision-model-preview`、`/v1/systemone`、示例 latency_ms 52.9
7. 阿里云：decision-model-preview 模型信息 — 访问日期 2026-10-14 — 更新 2026-10-11、输出长度 0、限时免费
8. 腾讯云 CMR：配置模型调度管理 — 访问日期 2026-10-14 — 更新 2026-10-13、分类决策模型如 Jev、开启分类决策模型
9. 腾讯云 TokenHub API 使用说明 — 访问日期 2026-10-14 — 更新 2026-10-13、无 `/v1/decisions`、模型表示例 hy3
10. 腾讯云 TokenHub × CC Switch 企业版 — 访问日期 2026-10-14 — 官方教 CC Switch 接 Token Plan
11. CC Switch v3.19.1 — 访问日期 2026-10-14 — Codex 腾讯混元预设、Cursor 不在支持列表
12. TT switch 公开笔记 — 访问日期 2026-10-14 — TT switch、腾讯内网、本地 `/v1/messages`
13. Jev × Cursor MCP — 访问日期 2026-10-14 — `jev_decide` 等工具、`.cursor/mcp.json`
14. jevwiki：Jev in agent harnesses — 访问日期 2026-10-14 — PreToolUse / beforeShellExecution
15. Microsoft-Decision-1 — 访问日期 2026-10-14 — 2026-10-09、0.042 美元/百万输入
16. Cloudflare Clef — 访问日期 2026-10-14 — 2026-10-01、System One 兼容
17. arxiv 2510.08731 — 访问日期 2026-10-14 — Semantic Router 论文
18. Vercel：OpenAI-Compatible Decisions — 访问日期 2026-10-14 — 网关 `/v1/decisions`
19. OpenAI DevDay 2026 Recap — 访问日期 2026-10-14 — 2026-09-29 limited preview

20. 混元 ChatCompletions / Tools — 访问日期 2026-10-14 — functioncall 仍为生成路径

五、方法论说明

本文采用横纵分析法（Horizontal-Vertical Analysis）。纵轴沿时间还原决策模型从分类器、Function calling 到独立 Decisions 端点的历程，横轴对比 OpenAI、Jev、阿里、微软、混元栈与 tt-switch，交汇后回答「hy 何时能出、该怎么接、调用发生在哪一层」。方法论由数字生命卡兹克提出；本报告由玉笛百科撰写。

司内论坛原帖、tt-switch 内部仓库与维护团队、混元 Decisions roadmap，公开检索均为暂缺，不编造。滚动延迟与校准数字以各厂商文档和社区实验为准，已标明性质。本报告不构成采购或接入承诺。