玉笛百科 JADE FLUTE

HORIZONTAL · VERTICAL ANALYSIS

Jev

横纵分析法深度研究报告

所属领域　AI 应用软件 / 决策模型 / Agent 基础设施
研究对象类型　产品
研究时间　2026年10月13日
研究方法　纵向历史溯源 + 横向竞品对比 + 交汇洞察
研究员　玉笛百科

ENCYCLOPEDIA REPORT

目录

核心结论速览 4
一、纵向分析：从诞生到当下 4
1.1 起源：教模型听话的人，决定不再让模型说话 5
1.2 隐身两年：给软件造一套 System One（2024–2026 年 9 月） 6
1.3 发布即品类：从 waitlist 到万亿 token（2026 年 9 月 15 日–21 日） 6
1.4 资本加冕与对手围拢（2026 年 10 月） 8
二、横向分析：竞争图谱 9
2.1 竞品地图 9
2.2 Jev 当前画像 9
2.3 vs vLLM-SR Decision 3.0 10
2.4 vs Microsoft-Decision-1 11
2.5 vs OpenAI Decisions API 12
2.6 vs Cloudflare Clef 与开源平替 12
2.7 维度对照 14
2.8 生态位与格局 15
三、横纵交汇洞察 15
3.1 历史如何塑造了当下位置 15
3.2 优势与劣势的历史根源 16
3.3 未来三个剧本 16
四、信息来源 18

五、方法论说明.....19

核心结论速览

一句话定义：Jev 是 TypeSafe AI 在 2026 年 9 月推出的「System One」决策模型：它读一段程序状态，并行回答一组预先定义好类型的问题，直接返回带校准概率的判断，不写字、不聊天、不生成代码。

关键判断：

1. Jev 的真正发明是接口，不是更大的脑子。它把软件里每天要做成千上万次的「分类、路由、打分、是否」从大模型的聊天接口里拆出来，变成一条可以嵌进控制流的函数调用。创始人 Diogo Almeida 本人就是 InstructGPT / RLHF 论文的共同作者，他从「教模型跟人说话」走到「不让模型对人说话」，这条反向路径解释了产品为什么长成现在这样。
2. 发布后 24 天内拿到 a16z 领投的 8.7 亿美元、估值 75 亿美元，核心在于它撞上了 Agent 落地的真实瓶颈：一次真正的 Agent 跑起来，大部分时间不是在「想」，而是在反复判断该调哪个工具、上下文还要不要留、结果要不要人工复查。这些判断交给会深度思考的大模型，又慢又贵。
3. 智东西 10 月 12 日那篇「Jev 对手来了」说的对手，是 vLLM Semantic Router 开源的 Decision 3.0。它不是唯一对手。10 月头两周，Cloudflare Clef、OpenAI Decisions API、微软 Microsoft-Decision-1 几乎同时入场。Jev 用封闭 API 定义了品类，开源权重和云厂商正在按同一套 `state + questions → typed answers` 协议把它摊薄。

机会与风险：

- 机会：谁先把「决策层」做成软件默认零件，谁就能吃到 Agent 流水线里最高频、最可计量的那一层调用。Jev 目前仍是这层里文档最完整、概率校准叙事最强、开发者心智最占先的托管产品。
- 风险：权重不开、不能看图、中文弱于英文、校准几乎没有独立验证。「零幻觉」只保证输出类型合法，不保证判断正确。开源多模态一旦在自有数据上够用，Jev 的溢价会迅速从「品类定义者」变成「贵一点的托管接口」。

一、纵向分析：从诞生到当下

> **叙事主线**：一个帮大模型学会「听话」的人，发现听话解决不了自动化。他隐身两年，造了一种故意不会写字的模型。模型一上线就变成品类；品类一成立，对手就按同一份协议涌进来。

1.1 起源：教模型听话的人，决定不再让模型说话

2022 年 3 月，OpenAI 发表 InstructGPT 论文《Training language models to follow instructions with human feedback》。作者名单里有 Diogo Almeida。官方博客《Aligning language models to follow instructions》把他列为共同作者，和他一起的还有 Long Ouyang、Jeff Wu、John Schulman、Paul Christiano 等人。那篇工作的核心动作很具体：先用标注员示范把 GPT-3 做监督微调，再收集输出排序，用人类反馈强化学习（RLHF）继续训。结果是 13 亿参数的 InstructGPT，在人类评估里胜过 1750 亿参数的 GPT-3。

ChatGPT 几个月后爆发。行业把 RLHF 写成「对齐」的标准配方。Almeida 后来说，他当时以为聊天模型也许会通向 AGI。做了几年之后，他改口了。官网第一句话写得很硬：「We took the opposite research direction」。官宣文里他写自己过去四年的驱动问题只有一句：模型已经超人级别地会聊天了，自动化为什么还是没来？

他给的答案很工程：电脑不讲人话。大模型输出的是字符串，软件要的是分支。字符串灵活，所以能写诗、写代码、也能幻觉、拒答、跑出 schema。要让程序用它，必须再解析、再校验、再重试。延迟按秒计，输出按 token 加价，置信度还对不上真实正确率。

2023 到 2025 年，行业把这个问题处理成 prompt 工程和 JSON mode。做法是：在系统提示词里把 schema 写死，要求模型「只输出 JSON」，再用正则或 pydantic 兜底。能用，也一直在用。代价是每次判断仍然走完整的自回归生成，模型会先在内心拟一篇分析，再把分析压成字段；字段偶发飘出类型，流水线就断。Agent 一流行，这个代价被放大。一个能在仓库里改文件、调浏览器、跑测试的 Agent，单次任务里可能要做几十上百次微型判断：这个工具现在该不该调、这条搜索结果还要不要、用户这句话是新任务还是追问、刚才那次补丁有没有把测试搞红。每一问都请 Claude 或 GPT 想一遍，账单和尾延迟会先把产品杀死。

软件里真正高频的活，从来不是写一篇对人类漂亮的回复。是工单归哪个组、这次要不要调工具、这段上下文还能不能留、这条内容过不过审。这些活以前用规则写死太脆，用大模型又太贵太慢。中间缺的是一种「模糊的 if」：能读自然语言和半结构化状态，但返回值必须能直接写进 `if`。

2024 年，Almeida 与前 Meta 研究工程师 Sasha Sheng、工程师 Erik Gafni 在旧金山创办 TypeSafe AI。Almeida 任 CEO，Sheng 任 COO，Gafni 任 CTO。公司隐身大约两年。2026 年 9 月 15 日退出隐身时，BusinessWire / SiliconANGLE 报道 DCVC 领投约 4000 万美元种子轮；Forbes 援引知情人士称估值约 2 亿美元，公司和 DCVC 未在官方稿里写这个数字。

公司名 TypeSafe，产品哲学写在名字上：给软件一种类型安全的智能原语。模型类名 System One，借自丹尼尔·卡尼曼《思考，快与慢》里的快系统。产品名 Jev，取自 19 世纪经济学家威廉·杰文斯。杰文斯悖论说的是：蒸汽机把煤烧得更省，煤的总消耗反而上升。TypeSafe 赌的是同一件事：智能一旦便宜到可以在代码里随处调用，调用量会爆掉。a16z 后来把这个现象直接叫成「Jev-ons paradox」。

1.2 隐身两年：给软件造一套 System One（2024–2026 年 9 月）

隐身期对外几乎没有论文。能确定的技术主张，都写在 9 月 15 日 Almeida 的官宣里。他们自称造了三样新东西：一套面向自动化的模型架构、一个并行采样器、一种叫 Reinforcement Learning for Calibrated Decisions（RLCD）的训练方法。

和 LLM 的对照表，是理解 Jev 的最短路径。

LLM 用 RLHF / RLVR 优化人类偏好或可验证奖励，输入偏对话，输出是字符串，采样是自回归，一个 token 等上一个。Jev 用 RLCD 优化「校准过的决策」：输入偏程序状态，输出是事先定义好的类型值，一次请求里所有问题并行出结果。官宣给出的成本是每百万输入 token 0.042 美元，输出免费；端到端 70 到 500 毫秒。他们把这组数字和前沿模型的 3 到 329 秒、输入 0.20 到 10 美元/百万 token 放在一张表里。首页更大胆：在自家 System One 工作流评测上，称快 193.6 倍、便宜 444.6 倍。官宣自己加了括号：这些数字落在真实收益的高端。

「校准」是他们最想卖的词。意思是：模型说 90% 把握，在代表性样本上大约应该对九成。文档写得很克制：校准是在一组预测上度量的，不保证单条答案正确。输出只有三种原语：

- Choice：从给定选项里选一个，例如工单该去 billing / technical / account。
- Score：在有序刻度上打分，例如客户愤怒程度。
- Noul：判断某事是否成立，返回 0 到 1 的概率，例如这封邮件是不是在要求退款。

一次请求的形状是 `state` 加一组 `questions`。`state` 可以是字符串、JSON 或文本数组。模型把 state 读一遍，所有问题对着同一份状态并行作答，每个答案带概率和 confidence。选项基数上限 255。超过这个数，官方演示用两阶段：先独立打分，再显式选择。

他们反复强调一件数学上成立的事：类型错误不可能发生。输出空间在请求里就锁死了，模型选不出 schema 以外的字段。官宣把这件事写成「can’t hallucinate」。这个句子后来被媒体原样传播，也成为后来最大的语义陷阱。它保证的是类型，不是真相。模型照样能把错误选项选得很自信。

参数量没有公布。文档写明：不对客户数据做微调或 LoRA，所有账号共用同一套用 RLCD 训出来的权重。领域适配靠把专有内容塞进 `state`，把业务规则写进 `instructions` 和 `criteria`，再在代码里把多个原子问题组合成工作流。输入目前只有文本，图像、音频、视频要先转成文字或结构化字段。英文是主训练语言，CJK「能用，但效果不等同」，文档要求非英文工作负载先用自己的数据测。

隐身两年真正锁死的，是产品形态：封闭托管、统一权重大家用、用请求而不是微调来定制、用类型而不是 prompt 来约束。后面所有优势和包袱，都从这四个选择长出来。

1.3 发布即品类：从 waitlist 到万亿 token（2026 年 9 月 15 日–21 日）

2026 年 9 月 15 日，Jev 以 early access 上线。同一天种子轮稿件发出。Almeida 把产品形容成「frontier-intelligence function call」：非结构化状态进，带类型的概率决策出。

增长数字来自公司和投资人，外部很难复核。a16z 10 月 9 日的投资声明写：Jev 是他们见过增长最快的模型，上线仅 3 天 token 用量达到 1 万亿。同一篇稿件写，25% 的 Fortune 500 已经接入。TechCrunch 同一天报道融资时写的是 TypeSafe 声称三分之一的 Fortune 500 已在用。两个口径差了八个百分点，都是宣称，不是经审计的客户名单。

中文报道补充了开发者侧的热度，需要当二手来源看。钛媒体 9 月 25 日文称：官宣帖在 X 上浏览量冲到数千万；Hacker News 当天 1800 多分、近 500 条评论；Vercel 上线 24 小时内近 13% 的付费团队接入；发布 36 小时内测申请涉及约 14 万开发者；9 月 21 日对所有人开放，新用户送 5 美元额度（约 1.2 亿 token）。这些数字没有官方逐条背书，但 9 月 21 日开放 API、按输入计费、输出免费，与现行文档一致。

社区用法比融资数字更能说明它撞上了什么。有人把它接进 Claude Code 清上下文：大量工具调用和终端输出交给 Jev 打分，只把仍与当前任务相关的片段留给大模型。有人拿 Agent 执行记录问它：目标完成了没有、有没有漏项、质量落在哪一档。有人用它在 40 秒里拆 724 条实时广告。官方自己的玩具更夸张：用结构化游戏状态驱动 Doom 机器人，每秒大约 10 次查询；用它玩维基竞速，每一步在成百上千个链接里选。Doom 演示明确写了：喂进去的是带文本的数据结构，还不是图像。

LangChain 做过一组小规模实验，让 Jev、GPT-5.6 Luna、GPT-5.6 Terra 和 Claude Sonnet 4.6 对固定的 Agent 输出反复评分。新浪转引的数字是：Jev 平均每次约 0.44 秒、约 0.00035 美元，一致性突出。LangChain 自己强调这是早期小样本，不能外推到生产。

冷水也来得很快。钛媒体引 Redis 作者 antirez 的公开批评：Jev 也许有一些很窄的场景，围绕它的炒作说明泡沫里的人分不清什么重要。也有人说它就是个 JSON 分类器。Sebastian Raschka 的反驳被同一篇文章记下：传统分类器标签训死了，场景一变要重训；Jev 能在运行时接收自然语言标签，对动态选项做判断。更说明风向的是：Jev 发布同一周，Cloudflare 公开了把 DiffusionGemma 改成决策接口的实验。品类还没满月，仿制已经开始。

如果把一个 Agent 拆开，Jev 这类模型至少能顶三个位置，这也是它在工程上真正值钱的地方。

第一个位置是模型路由。进来一条请求，先问：这是闲聊、查资料、写代码，还是根本不用模型、走规则就能回？选错的代价不对称：简单问题发给最贵的推理模型，浪费钱；复杂问题发给小模型，用户感知到蠢。决策模型的输出带着概率，路由层可以写成：高于阈值走小模型，低于阈值升级，命中安全类别直接拒。以前这件事也会做，只是每次路由本身就是一次 LLM 调用。

第二个位置是工具门槛。Agent 的工具列表越来越长，每次都让大模型在 30 个工具里挑，既慢又容易幻觉出不存在的函数名。Jev 的 Choice 把工具名锁在 `criteria` 里，选不出来的名字根本不在输出空间。Noul 则负责更前置的一问：现在需不需要工具。很多请求的正确答案是「不需要」，省掉一次搜索或一次代码执行，比把搜索做对更重要。

第三个位置是验证与监督。大模型写完一段补丁、拟好一封客服回复、规划好下一步点击，系统需要一个外部裁判：有没有完成目标、有没有违反政策、质量落在哪一档。再请一个同样会写字的模型来审，等于用生成检查生成，慢，还容易共谋式地放水。决策模型不写评语，只打分。LangChain 那组小实验看中的，就是这种重复评分时的稳定性。

三个位置叠在一起，Agent 的架构从「全程 LLM」变成「规则 + 决策模型 + LLM + 工具」。LLM 仍然负责复杂推理和生成，Jev 负责那些又小又急的判断题。发布第一周的 demo 看起来像玩具，骨架已经是这个分层。

这一周真正完成的，是心智占领。开发者第一次有一个可以抄的协议：`POST /v1/systemone`，`state` + `questions`，回来的是 Choice / Score / Noul。后来所有对手，包括智东西文章里的 Decision 3.0，都在抄这张表。

1.4 资本加冕与对手围拢（2026 年 10 月）

2026 年 10 月 9 日，TypeSafe 宣布新一轮融资。TechCrunch 报道：a16z 领投 8.7 亿美元，估值 75 亿美元，Sequoia 和老股东 DCVC 跟投。a16z 署名 Jennifer Li、Sarah Wang、Martin Casado、Marc Andreessen、Ben Horowitz。稿件把 Jev 称为「今年见过最大的叙事违规」：一边是大实验室继续堆参数、上下文和类人推理，一边是 TypeSafe 把智能送回开发者手里，让软件变聪明，而不是用 AI 把现有软件再写一遍。

从种子轮宣称的约 2 亿美元，到 24 天后的 75 亿美元，中间几乎没有新的技术论文，只有用量、开发者 demo 和「我们定义了一个品类」。资本买的是接口标准和时间窗口。

窗口立刻被挤满。按公开时间排：

- 10 月 1 日：Cloudflare 发布开源决策模型 Clef / Clef-flash，Apache-2.0，挂在 Workers AI 上，API 按 Jev 的 System One 形状兼容，并宣布后续提供微调。
- 10 月 6 日：OpenAI Decisions API 进入公开 beta，模型是 `gpt-6-luna`，`POST /v1/decisions`，支持文本和图像，输入 0.10 美元/百万 token，输出免费，官方称比同一模型走 Responses API 做决策快最多约 10 倍。
- 10 月 9 日：微软发布 Microsoft-Decision-1，基于 Qwen3.5-9B 后训练，走 Microsoft Foundry 和 OpenRouter，定价直接写成每百万输入 0.042 美元、输出免费，和 Jev 同一价签。
- 10 月 11 日前后：vLLM 社区孵化的 vLLM Semantic Router 开源 Decision 3.0 系列，权重放在 Hugging Face，旗舰 d3 基于 Qwen3.8-27B，能看多图和视频。智东西 10 月 12 日的文章把这件事写成「Jev 对手模型来了」。

现行文档里的 Jev 已经迭代到 `jev-1.13.0`，别名 `jev-latest`。上下文预算是每请求 64k，其中 `state` 加最长一个问题不得超过 32k。限流写的是每秒 10 万 token、每秒 80 请求，文档声明需求太大，限额会动态调整。服务节点在美国西海岸。企业可签零数据保留。

纵向走到 2026 年 10 月 13 日，故事已经换了主题。前两周的主题是「一种新模型」。这一周的主题是「一种新协议」。Jev 还是这个协议上文档最完整的托管实现，但它已经不是唯一实现。

二、横向分析：竞争图谱

> 切面时间：2026 年 10 月 13 日。触发材料是智东西 10 月 12 日关于 vLLM Semantic Router Decision 3.0 的报道。

2.1 竞品地图

这是场景 C：直接竞品在三周内超过五个，而且接口几乎同构。对比对象按「会不会被用户拿来替 Jev」来选，不把中科闻歌 Decitron 这类世界模型 / 博弈推演系统算进来。Decitron 做的是对未来的推演，Jev 做的是当下的一次判断，名字里都有「决策」，工程对象不是一类。

五个代表：

1. vLLM-SR Decision 3.0：智东西点名的对手，开源权重、多模态、本地可部署。
2. Microsoft-Decision-1：企业云里的官方决策模型，价签对齐 Jev。
3. OpenAI Decisions API：实验室把现有聊天模型开了一条决策专用通道。
4. Cloudflare Clef：第一个高调开源、API 兼容、还承诺微调的云厂商产品。
5. 开源平替群（Kev / Laya 等）：证明「抄接口」的训练成本可以低到个人项目。

2.2 Jev 当前画像

定位：封闭托管的 System One 旗舰。用户买的是一个稳定的 `POST /v1/systemone`，不是一张可以搬回家的权重。

核心能力写在文档和官宣里，能够核对：

- 三种强类型输出，并行多问，选项最多 255。
- 输入百万 token 0.042 美元，输出不收费。
- 官方延迟 70–500 毫秒；Cloudflare 自己测到的 Jev 中位延迟 524.1 毫秒（硬件环境未与 TypeSafe 对齐，只能当量级参考）。
- 64k 请求上下文，文本 / JSON / 文本数组。
- 版本化模型 ID，阈值调好以后可以钉死 `jev-1.13.0`，避免别名滑动。
- 官方工作流评测自称占据速度-成本帕累托前沿；同时承认相对最强外部模型的参考概率，Jev 并不总是更准。

短板同样写在自己的文档和对手的模型卡上：

- 不能看图、不能看视频。
- 不能按客户数据微调。
- 英文主场，中文和其它 CJK 要自测。

- 权重封闭，无法私有化、无法离线、无法做合规审计意义上的「模型在我这」。
- 「零幻觉」是类型保证。独立评论指出，主流 Decision Index 收了全部分布概率，却不算 ECE、Brier、可靠性曲线，Jev 最想卖的校准几乎没有第三方成绩单。

目标用户是要把判断嵌进代码的人：Agent 作者、工作流引擎、客服路由、内容审核、模型网关。商业模式是 API 计量，企业另开更高限额和零数据保留。TypeSafe 不靠卖卡、不靠开源获取、不靠让客户训出自己的模型。护城河如果存在，就在校准质量、高基数选项、文档 / SDK 完成度，以及先到的开发者心智。

口碑两极。一边是「终于有一个可以当 if 用的模型」；一边是「JSON 分类器被 75 亿估值」。两边说的其实是同一件事：它把一件小事做成了基础设施。小事值不值这个价，要看 Agent 流水线里判断调用的密度，以及开源平替多久能在自有数据上追上。

实际接入时，Jev 的用法比「换一个更快的分类器」更啰嗦，也更有约束力。文档推荐的路径是：先把一个大判断拆成许多原子问题，让每个问题只问一件事；把专有政策、历史工单、库存状态放进 `state`；把边界情况写进 `criteria`；在代码里用概率做与或、做加权，而不是把模型的 Choice 直接当成最终动作。官方 cookbook 里有一个叫 SDE cascade 的例子：便宜的小生成模型先抽字段，Jev 用一组 Noul 去抓「这个字段可能抽错了」，超过阈值再升级到更贵的推理模型。AutoResearch 则更进一步：让另一个 LLM 提议该问哪些问题，Jev 对每一行数据作答，答案变成 CatBoost 的数字特征，再根据错误样本改问题。这两份配方说明 TypeSafe 想占据的位置，是特征工厂和门卫，不是聊天机器人替代品。

中文场景要单独说一句。文档写明英文是主场。客服分流、内容审核、代码 PR 分类这些活，中国团队每天也在做，但直接把中文工单丢给 Jev，官方自己都不建议依赖。服务节点在美西，时延和合规叠在语言之上。对国内使用者，Jev 更像一份接口规范和一组英文评测基线；能落地的往往是 Decision 3.0、Clef，或自己用通义后训练出来的本地判断器。品类的意义在，接口已经有了；产品的意义在，英文云端工作流里它可以马上用。

2.3 vs vLLM-SR Decision 3.0

Decision 3.0 是这条微信链接里的「对手」。vLLM Semantic Router 团队在 Hugging Face 上放出六个检查点：d3（约 26.09B，含 0.46B 视觉编码器）、d3-flash（约 8.4B）、d3-mini、d3-nano、d3-lite、d3-edge（约 0.6B）。许可证 Apache-2.0。旗舰基于 Qwen3.8-27B，其余基于不同规模的 Qwen3.5。调用形状几乎照抄 System One：`model.system_one(state=..., questions=...)`，本地也能用 `vllm-sr serve` 开出 `/v1/systemone`。

和 Jev 的本质差别有三条。

第一，能看。d3 接受多张 PNG / JPEG / WebP，以及 MP4 / WebM / MOV / MKV 视频，默认 2 帧/秒、最多 32 帧。智东西举的例子很具体：客户说搅拌机破了，附收据图和配送视频，一次请求里同时回答该由哪个团队处理、收据上有没有这台机器、包裹怎么送达。Jev 要把图和视频先转成文字，信息在预处理里就已经丢了一层。

第二，能搬回家。权重公开，可在自有 GPU 上跑。模型卡给出的单卡数字：一张 AMD Instinct MI325X 上，文本请求中位延迟 54.4 毫秒，带图 290 毫秒，10 秒视频约 500 毫秒；Engine 模式下单卡文本大约 27 请求/秒。有开发者把 d3-lite 用 Core ML 打到 M5 Pro 的 Mac 上，给 1000 个 PR 做工作组分类，总耗时约 2 分钟。这些数字是厂商或社区自测，但方向清楚：决策模型开始变成可以塞进笔记本和边缘的零件。

第三，榜上暂时领先。智东西引用的 Jev Decision Index 0.3.1：d3 文本 64.7、公开集 65.5，高于 Jev 的 60.1；视觉榜 71.6。d3 模型卡更新到 0.3.2 时自称文本 66.3、视觉 71.3，在 149 个文本条目里第一。独立站点在 10 月 12 日的再生榜上也写过 vLLM-SR d3 领先。必须立刻加的限制：Decision Index 的满分里大约 20% 来自公开集，50% 来自同技能私有题，30% 来自新域私有题，外人无法复现那 80%。它测的是广度上的准确率，不是校准。Jev 在 0.3.1 公开榜上仍是第一阵营，并没有被打出品类。

Decision 3.0 的代价是运维。你要备 GPU、处理量化、对齐 kernel、自己做评测集。Jev 卖的是「阈值调好就能用」。对已经把判断写进生产、并且依赖那套 confidence 门槛的团队，搬家成本高于下载权重。对必须处理截图、单据、录像，或者数据不能出境的团队，d3 是更合理的第一选择。

2.4 vs Microsoft-Decision-1

微软 10 月 9 日的稿件，作者是 CTO 办公室软件工程 VP Achint Srivastava。产品定位几乎逐句翻译 Jev：给固定选项打校准概率，用于路由、分类、优先级、校验、工作流控制、Agent 护栏。它从 Qwen3.5-9B 后训练，承诺以后会 rebase 到 MAI 和 OpenAI 模型。Foundry 文档里的请求路径是微软自己的 `/v1/systemone`，字段仍是 `state` 和 `questions`（noul / choice / score）。

微软没有走「我们发明了品类」，走的是「我们在自己的生产里已经这么用了」：

- Xbox Research 用它处理超过 1 万条开放反馈，按研究员定好的主题归类，称质量接近 GPT-6 Sol，快 14 倍以上，便宜约 200 倍。
- Copilot 团队拿它做聊天和 Agent 回复质检，称与 GPT-5.6 Luna 接近，快 100 倍。
- 值班工程师用它在日志和工单里检索相关知识，称比 LLM 更好更快。
- Microsoft Discovery 用它给科学实验的自适应重规划打分，称一致性是 LLM 打分的 46 倍。

自家 36 项、近 15 万题的对比里，微软称 Decision-1 准确率最高；P50 延迟大约是 GPT-6 Sol 的 1/35，比当时第二的 H2O-Lightning-4B v1.1 快 2.5 倍。稳健性测试：八种扰动平均 1.3% 的决策翻转，选项描述改写或选项顺序打乱时零翻转。定价与 Jev 相同：0.042 美元/百万输入，输出免费。OpenRouter 列出的上下文大约 32k。

对已经在 Azure 里跑 Copilot 和工作流的企业，Decision-1 的意义是采购路径，不是算法故事。它降低了「决策模型」进入安全审查名单的摩擦。对 Jev 的压力来自价签对齐：微软用 9B 后训练模型，按同一单价出售，还附带 Foundry 的合规包装。Jev 若不能在校准、高基数选项和一致性上拿出可复核的差距，企业会问一句：为什么不买微软的?

智东西引用的 0.3.1 榜上，Decision-1 文本 53.2，低于 d3 和 Jev。微软的回应写在自己的稿件里：他们拿 JevBench 上的热门公开模型，到另外 36 个公开加私有基准上测，Decision-1 更会泛化。两套榜互相不认，是这个品类眼下的常态。

2.5 vs OpenAI Decisions API

OpenAI 10 月 6 日把 Decisions API 放进公开 beta。社区公告写：让应用近实时选择模型、工具或动作；由 GPT-6 Luna 驱动；输入可以是文本和图像；三种输出是 predicate（命题为真的概率）、choice、score。定价 0.10 美元/百万输入 token，大约是 Jev 的 2.4 倍，输出同样免费。官方称比同一模型走 Responses API 做决策快最多约 10 倍。Node SDK 在同一天出现了独立的 `client.decisions.create`。

这是实验室路线。它没有宣称新架构或 RLCD，而是给已经会聊天的模型开了一条更快的决策通道。优点是生态：账号、数据协议、图像输入、未来和 Responses / Agents 的衔接，都在同一栋楼里。缺点也清楚：它仍然是「大模型在做判断」，只是少写字、少收费。Jev 官宣里最得意的 40 到 200 倍速度差，对 OpenAI 自己的 Decisions 端点会缩小。

对 Almeida 个人，这个对手有一层传记意味。他在 OpenAI 参与了让模型听话的方法，离开后去做不说话的模型。老东家没有否认品类，而是把品类收进 GPT-6 的产品矩阵。Jev 若只是「结构化输出的快模式」，OpenAI 可以在自己的栈里复制；Jev 必须证明并行采样加 RLCD 在校准和一致性上，仍然不是 Luna 套一层 schema 能替代的。

2.6 vs Cloudflare Clef 与开源平替

Clef 是 10 月 1 日的第一枪。27B 的 Clef 和 9B 的 Clef-flash，Apache-2.0，Workers AI 托管，Hugging Face 放权重。Cloudflare 写明：Jev 兼容，换模型名就能试。它强调三件事：有视觉编码器；上下文 64k（稿件里把它写成对 Jev 32k 的优势，对应的是 Jev 文档里 state+最长问题 32k 那一档，请求总预算其实已经是 64k）；以及客户可以微调。

训练叙述比 TypeSafe 更透明。骨干冻结 Qwen，推理时只做 prefill，再对合法 schema 选项并行打分，非自回归。后训练用标签平滑交叉熵加 Brier loss，再把 RLCD 当作第二优化目标。Clef-flash 用的是 Qwen3.5-9B。Cloudflare 在自测的 10 项与决策相关的基准上，多数项目高于 Jev；中位延迟 Clef 209.3 毫秒、Clef-flash 38.8 毫秒，Jev 524.1 毫秒。TypeSafe 四项工作流上，Clef 在发票、客服、安全事件三项略高，Agent trace 一项略低。这些是厂商自测。

独立测试并不完全站在 Cloudflare 一边。有开发者在 1048 道题上比较：Jev 1.13 正确 805 题（76.8%），Clef 27B 733 题，差异显著。同一文同意 Cloudflare 的一个短板：Clef-flash 在「以上都不是」这类选项上明显弱于 Jev（61% 对 86%）。Arize 的另一组测试则把 Jev、Clef 27B、Liquid d1 放在幻觉识别上只差一个百分点左右，并写「发布三周后，头部决策模型在准确率上已经商品化」。

Kev 把商品化写得更刺眼：有报道称第一轮跨三个尺寸的训练大约只花了 95 美元租来的 GPU 时间，接口按 Jev 抄。Laya 以约 4 亿参数、能在 CPU 上跑、还带多语言作为卖点，但多家评测把它放在接近随机的位置，校准很差。开源平替证明了两件事：协议可以复制；复制之后质量方差极大。Jev 目前仍在「能直接设阈值」这一档里被人点名，Kev 在「可私有化微调」这一档被人点名。

2.7 维度对照

维度	Jev	Decision 3.0（d3）	Microsoft-Decision-1	OpenAI Decisions	Cloudflare Clef
出品方	TypeSafe AI	vLLM Semantic Router	微软	OpenAI	Cloudflare
公开时间	2026-09-15	约 2026-10-11	2026-10-09	2026-10-06	2026-10-01
形态	封闭 API	开源权重 + 可自托管	Foundry / OpenRouter	实验室 API	托管 + Apache-2.0 权重
骨干	未公布	Qwen3.8-27B	Qwen3.5-9B 后训练	GPT-6 Luna	Qwen3.8-27B / 3.5-9B
输入	仅文本	文本 + 多图 + 视频	文本（官方未强调视频）	文本 + 图像	文本 + 图像
输出	Choice / Score / Noul	同左	同左	predicate / choice / score	兼容 System One
输入定价	0.042 美元/百万 token	自备算力	0.042 美元/百万 token	0.10 美元/百万 token	Workers AI 计量；有报道约 0.24 美元/百万
官方延迟量级	70–500 毫秒	文本中位约 55 毫秒（MI325X）	称快于多数决策模型和 GPT-6 Sol	称比 Responses 快最多约 10 倍	中位约 209 / 39 毫秒
微调	不提供	可自训	未作为主卖点	走实验室模型迭代	明确提供 FDE / RL 微调
中文 / 本地	CJK 弱于英文；节点在美西	可本地，基座是通义	走 Azure 合规	走 OpenAI 账号	边缘节点
当前叙事	品类定义者、校准、高基数	开源多模态、榜首	企业生产、稳健性	生态内决策通道	兼容 + 视觉 + 可训

2.8 生态位与格局

格局是「协议已定、实现混战」。Jev 填补的空白，是 2026 年夏天 Agent 系统里那一层又急又碎的判断。它没有消灭 LLM，而是把 LLM 从「什么都问它」里解放出来。大模型继续写代码、做多步推理、生成给人类看的文字；Jev 这类模型做路由、验收、过滤、分级。

两强争霸还不成立。一边是 TypeSafe 的封闭旗舰，一边是 Qwen 后训练开源家族（d3、Clef、Decision-1 都从通义出发）。OpenAI 是第三条线：不承认自己只是套壳，但也不需要新公司来定义协议。用户真实选择已经开始分层：

- 要零运维、选项很多、想直接拿 confidence 设阈值：先看 Jev。
- 要看图看视频、要私有化、要本地：先看 Decision 3.0 或 Clef。
- 人在 Azure / 微软安全边界里：Decision-1 是最小阻力。
- 人已经在 OpenAI 栈里：Decisions API 少接一条新供应商。
- 要自己的标签数据：Clef 的微调叙事和 Kev 的可训开源，比 Jev 的「全员同一套权重」更对口。

Jev 仍占品类命名权。Decision Index、JevBench、甚至开源项目名里的 Jev-style、AnyJev、JEV-27B，都在用它的名字当单位。这是心智胜利。心智胜利能维持溢价多久，取决于校准能不能被第三方测出来，以及文本-only 在多模态对手面前能守住多少生产场景。

三、横纵交汇洞察

3.1 历史如何塑造了当下位置

Almeida 在 OpenAI 的工作，是让模型输出更像人想看的文字。那个成功把整个行业锁进聊天窗口。Jev 的位置，是他从同一条经验里抽出的反命题：人喜欢的文字，软件依赖不起。

所以 TypeSafe 做了四件在当时看起来像自废武功的事。放弃生成，就得到并行采样和类型锁定。放弃客户微调，就得到一套全球共用的校准过的权重，阈值可以跨账号复用。放弃开源，就得到 24 天 75 亿美元估值的稀缺性。放弃多模态，就先把文本决策的延迟和价格打到软件经济学能接受的区间。

每一项都在横轴上变成可攻击面。Decision 3.0 打多模态和开源。Clef 打微调和边缘。微软打价签与合规。OpenAI 打「你的决策通道本来就可以长在 GPT 上」。Jev 今天仍能排在第一阵营，是因为那四项自废武功先把它做成了唯一能被全行业抄的接口。抄袭是对标准的承认。标准的发明者一旦被抄，就要靠深一层的质量活下去。

a16z 写「叙事违规」，指的是大实验室还在用类人智能替代软件工程师。Jev 的历史选择是相反的：把智能降级成零件，交给工程师去组合。这个选择让它站在开发者一边，也让它必须接受零件被替代的命运。螺丝发明者很难对螺丝收软件估值，除非这颗螺丝的公差（校准）短期无法复制。

3.2 优势与劣势的历史根源

今天能看见的强项，都能追到隐身期的决策。

强项一：接口像代码。 来自「输出空间先验」。软件之所以能设阈值、能组合、能把 Jev 塞进 100 毫秒的热路径，是因为 2024 年他们决定不返回字符串。

强项二：便宜到可以乱花。 来自并行采样和「输出免费」。杰文斯命名不是装饰。3 天 1 万亿 token 这种宣称，只有在单次判断便宜到接近噪声时才可能发生。Agent 里判断次数远多于「写一篇回复」的次数，价格弹性在这一层最大。

强项三：叙事完整。 来自创始人履历。InstructGPT 共同作者说「聊天解决不了自动化」，比一家无名分类公司说同一句话，更容易让开发者和资本同时相信。75 亿估值里，有相当一部分买的是这个人的反向 arc。

今天能看见的包袱，也是同一组决策的利息。

包袱一：「零幻觉」说过头了。 类型安全在隐身期是正确的产品约束，写成营销句之后，被理解成判断不会错。独立基准又正好不测校准。卖点最硬的地方，证据最软。

包袱二：文本-only。 2026 年 9 月要先打速度，这个选择合理。10 月客服场景已经在塞收据照片和配送视频。预处理成文字，等于把多模态对手请到自己的主场门口。

包袱三：不能微调。 「同一套权重 + 请求里写规则」保证了校准叙事的干净，也拒绝了最赚钱的企业需求：用十年工单标签训一个只属于我的路由头。Clef 把微调写成产品，就是冲着这道门。

包袱四：封闭。 它让 TypeSafe 在 24 天内完成从种子到 75 亿的跳跃，也让 vLLM、Cloudflare、个人开发者可以在协议层合法地围猎。协议开放、权重大开的那一天，托管溢价只剩下 SLA、校准和 255 选项这种具体能力。

准确率从来不是 Jev 的主场。钛媒体转引的 Banking77 数字是 Jev 81.0%、Claude Opus 5 84.4%；官方工作流里 Jev 67.8%、最强基线 74.1%。这些数字若大体属实，故事就更清楚：人们抢着用它，是因为它够快够便宜、输出能进代码，不是因为它更聪明。聪明留给 System Two。Jev 的历史任务是把 System One 从人脑类比，落成一项云服务。

3.3 未来三个剧本

- 最可能：决策模型变成和 embedding 类似的默认层。Jev 继续做托管标准，份额被开源 Qwen 系（d3 / Clef / 各种 9B）和云厂商（微软、OpenAI、Cloudflare）切开。TypeSafe 靠校准、高基数、企业 SLA 和 SDK 活在「贵一点但省心」的位置，估值从 75 亿往下修，但仍是品类里的 Elasticsearch 而不是 Lucene。Agent 框架会同时内置 Jev 和本地 d3-flash，热路径用小模型，争议样本升到 Jev 或大模型。多模态成为标配，Jev 若在 2027 年还不能看图，会从「默认」变成「文本专用」。

- 最危险：校准叙事被独立评测戳破，同时开源多模态在自有集上追平准确率。企业发现 90% confidence 并不对应 90% 正确，阈值策略失效，决策层退回「再叫一次 LLM 但用 JSON mode」。75 亿估值对应的是「新智能原语」，一旦被重新分类为「快分类器」，资本和开发者会一起离开。另一个危险变体是 OpenAI / 微软把决策通道做成账号内免费或近免费的附带能力，Jev 作为独立供应商失去存在理由。
- 最乐观：RLCD 和并行采样被证明在校准和一致性上有真实、可复现的优势，Jev 补上视觉，仍保持封闭。它成为软件里的默认 `if`，用量随 Agent 部署指数上升，杰文斯悖论兑现。TypeSafe 从模型公司长成决策基础设施公司，协议兼容层（Clef、d3）反而帮它把 System One API 推成行业标准，类似 Kubernetes 旁仍能长出 GKE。那时候 75 亿看起来像早鸟价。

我的判断偏「最可能」靠近「略悲观」的那一侧。品类是真的，Jev 作为命名者的位置也是真的。24 天 75 亿买的是窗口，窗口在 10 月上旬已经关上。智东西那篇文章的价值，不在于 d3 比 Jev 高几分，而在于它宣布：对手可以开源、可以看图、可以按同一份协议插进你的代码。Jev 的意义已经完成了前半句——把判断做成软件零件。后半句是零件会不会还印着 TypeSafe 的商标。

回到用户那句最直白的问题：Jev 是什么，有什么意义。

它是一个不会聊天的模型，专门给软件做判断。你给它一段状态和几个事先定义好的问题，它返回选项、分数或是非概率。快，便宜，输出能直接写进代码。创始团队来自把 ChatGPT 教听话的那条研究线，产品却站在聊天的反面。

意义分三层，一层比一层硬。

工程层：Agent 和业务自动化缺的不是更会写的模型，是一层可靠的微型判断。没有这层，系统会把路由、验收、过滤全部外包给生成模型，又贵又抖。有了这层，生成模型可以只在真正需要推理和成文的时候出场。Jev 把这层做成了可调用的云函数。

产业层：它证明「不做生成」可以独立成一个融资叙事和一套 API 标准。三周内微软、OpenAI、Cloudflare、vLLM 全部按同一形状入场，说明这个空位是真的。开源多模态对手来得这么快，也说明空位一旦被指出，封闭模型守不住独家。

认知层：过去四年行业默认智能的界面是对话。Jev 把界面改回函数。函数没有文采，但软件是由函数组成的。模型已经很能聊的那几年里，自动化没有随之而来，卡点往往就在这里：智能的形态和软件的形态合不上。Jev 合上了一小块。一小块就足以掀起品类；一小块也不足以支撑永久的 75 亿溢价。

对要不要用它，可以用更具体的规则来选。判断题是封闭的、发生频率高、需要进控制流、英文为主、可以接受数据出境：值得先拿 Jev 做基线，用自己的几百条标注设阈值。判断题带着截图或录像、必须私有化、要吃中文工单或历史标签：直接看 Decision 3.0 或 Clef，把 Jev 当作协议说明书来读。需要写字、需要开放域推理、需要解释给人类看：它帮不上，那是 LLM 的活。

四、信息来源

1. TypeSafe 官网 — 访问日期 2026-10-13 — 反向研究方向、RLCD、首页 193.6x / 444.6x 宣称、0.042 美元/百万 token
2. Introducing System One Models & Jev（Diogo Almeida） — 访问日期 2026-10-13 — 发布日主张、与 LLM 对照、命名来源、Doom / Wikiracing、工作流评测限定
3. TypeSafe Models 文档 — 访问日期 2026-10-13 — `jev-1.13.0`、定价、64k/32k 上下文、仅文本、不可微调、CJK 限制、限流
4. TypeSafe System One 概念文档 — 访问日期 2026-10-13 — Choice / Score / Noul、校准口径
5. a16z：Investing in TypeSafe AI — 访问日期 2026-10-13 — 领投声明、3 天 1 万亿 token、25% Fortune 500、Jev-ons paradox
6. TechCrunch：Jev 开发商估值 75 亿美元 — 访问日期 2026-10-13 — 8.7 亿美元、a16z / Sequoia / DCVC、联合创始人、三分之一 Fortune 500 宣称
7. OpenAI：Aligning language models to follow instructions — 访问日期 2026-10-13 — Diogo Almeida 为 InstructGPT 共同作者
8. InstructGPT 论文 arXiv:2203.02155 — 访问日期 2026-10-13 — RLHF 指令跟随方法
9. SiliconANGLE：TypeSafe 退出隐身与 4000 万美元种子轮 — 访问日期 2026-10-13 — DCVC 领投、Forbes 2 亿美元估值传闻
10. 智东西：0.6B 起！Jev 对手模型来了 — 访问日期 2026-10-13 — Decision 3.0 系列、0.3.1 榜、微软 Decision-1、应用示例
11. Hugging Face：vllm-sr/d3 — 访问日期 2026-10-13 — 参数量、多模态、延迟、Decision Index 0.3.2、Apache-2.0
12. Hugging Face：Decision 3.0 Collection — 访问日期 2026-10-13 — 六档模型
13. 微软：Introducing Microsoft-Decision-1 — 访问日期 2026-10-13 — 产品定位、内部用例、定价、稳健性 1.3%
14. Microsoft Learn：在 Foundry 使用 Microsoft-Decision-1 — 访问日期 2026-10-13 — API 形状
15. OpenRouter：Microsoft-Decision-1 — 访问日期 2026-10-13 — 0.042 美元定价、32k 上下文、2026-10-09 发布
16. OpenAI 开发者社区：Decisions API Public Beta — 访问日期 2026-10-13 — 2026-10-06、gpt-6-luna、0.10 美元/百万 token
17. Cloudflare：Introducing Clef — 访问日期 2026-10-13 — 2026-10-01、开源、视觉、微调、自测延迟与基准、训练方法
18. 钛媒体：不写字的 AI 凭什么刷屏 — 访问日期 2026-10-13 — 社区热度、用法、antirez / Raschka 评论、Banking77 转引数字（二手，需折扣）
19. Jev Got Benchmarked Twice. Neither Tested Calibration. — 访问日期 2026-10-13 — Decision Index 不测校准

20. Decision Index 说明（JevDirectory） — 访问日期 2026-10-13 — 20/50/30 权重、延迟门槛
21. Arize：Decision model benchmark — 访问日期 2026-10-13 — Jev / Clef / Liquid / Kev 对照，商品化判断

五、方法论说明

本文采用横纵分析法（Horizontal-Vertical Analysis）。纵轴沿时间还原对象的生命历程，横轴在当前截面与同类对比，两条轴交汇后给出判断。方法论由数字生命卡兹克提出；本报告由玉笛百科撰写。

融资客户数、3 天 1 万亿 token、Fortune 500 占比均为公司或投资人宣称，正文已标明。Decision Index 含大比例私有题，不能当作可复现的能力证明。校准是 Jev 的核心卖点，截至本报告撰写日，仍缺少可公开复核的 ECE / 可靠性曲线。搜不到的细节（Jev 参数量、完整客户名单、RLCD 论文）标为未公开，不编造。